OpenAI ten-proofs

横纵分析法深度研究报告

研究时间：2026年8月4日 I 所属领域：AI for Mathematics / 形式化证明 / 理论计算机科学 I 研究对象类型：开源研究工件与研究方法论

作者: 数字生命卡兹克

> 研究时间：2026年8月4日 | 所属领域：AI for Mathematics / 形式化证明 / 理论计算机科学 | 研究对象类型：开源研究工件与研究方法论

目录

1. 一句话定义
2. 纵向分析：从诞生到当下
3. 横向分析：竞争图谱
4. 横纵交汇洞察
5. 信息来源
6. 方法论说明

一、一句话定义

ten-proofs 不是一套可复用的证明引擎代码库，而是 OpenAI 用内部下一代模型 Astra，在约一周、约 2000 美元量级 token 成本下，对十个「至少十年没有核心进展」的数学与理论计算机科学开放问题给出证明，并把每一条论证落成可机器校验的 Lean 4 证书、公开论文与推理叙事的研究方法发布包。

它真正卖的不是「又解了十道题」，而是一套面向研究级开放问题的**可审计生产流程**：选题门槛、模型发现、人工整稿、形式化、独立核校验、归因声明，全链路打包。

二、纵向分析：从诞生到当下

2.1 起源：当「能做题」不再够用

2024 到 2025 年间，AI 数学能力的公共叙事几乎被竞赛绑住了。DeepMind 的 AlphaProof / AlphaGeometry 在 IMO 上拿银牌级正式解，Harmonic 的 Aristotle、ByteDance 的 Seed-Prover 继续把「金牌等价」往形式化方向推；OpenAI 与 DeepMind 也在自然语言解上宣称金牌级表现。那时候大家比的是：同一套试卷、同一套评分、同一个「像不像人类选手」。

但研究数学不是考试。考试有标准答案与有限时间；研究有的是几十年没人动的猜想、跨领域的冷知识，以及「证明看起来对、其实漏了一行」的恐惧。

另一条暗线同时长起来。Thomas Bloom 在 2023 年搭起 erdosproblems.com，把 Erdős 散落在上千篇论文里的问题收成可检索清单。到 2025 年底评论区开放后，这里迅速变成业余研究者、本科生、职业数学家和 AI hobbyist 的公共靶场。Quanta 在 2026 年 8 月的长文里写得很清楚：大公司后来也把这份清单当作非正式 benchmark——因为「开放问题仓库」比 IMO 更接近真实研究的抽样方式。

OpenAI 自己的叙事起点，则落在 2026 年 5 月 20 日：一个未发布内部模型给出了 Erdős 单位距离猜想的反例。这不是「又刷了一道竞赛题」，而是用代数数论里的构造手段，推翻了一个被广泛相信为真的离散几何猜想。随后一批顶尖数学家（含 Gowers、Alon、Tsimerman 等）写了 human-digested 评注稿；Gowers 甚至说，若这是人类投稿 Annals，他会毫不犹豫建议接收。那一次发布的署名方式很刺眼：作者栏写的是 “OpenAI”。

单位距离结果还带来一个副作用：数学共同体开始认真讨论 **AI 结果该怎么署名、怎么归功、怎么审核**。2026 年 6 月初的 Leiden Declaration 直接点名：不可靠证明、归因缺失、闭源依赖、过度炒作、研究议程被商业绑架。OpenAI 的 unit-distance 发布，在宣言作者们的讨论里被当作风险样本之一。

所以 ten-proofs 不是从零冒出来的炫技仓库。它是在「竞赛金牌叙事」与「开放问题研究」两条线交叉后，OpenAI 用更重的验证标准，对 Leiden 批评作出的制度化回应。

若再往前追半步，会看到更早的方法论伏笔。形式化数学社区花了十年把 mathlib 做成可依赖的公共库；Lean FRO 把证明助手从「专家玩具」推向工程基础设施；Comparator、nanoda 这类独立检查工具的出现，则让「我不信任你们的编译器」也能被制度化回应。OpenAI 并没有发明 Lean，它只是在需要向外界证明自己没在吹牛时，选了共同体已经准备好的硬通货。

另一条伏笔来自提示工程与 agent 编排。Scientific American 对 Cycle Double Cover 一事的报道提到：人类写的 prompt 大量是 scaffolding，目的是强迫模型投入足够算力、禁止它轻易回答「这题未解决」、并调度多达 64 个并行子代理互相纠错。hobbyist 在 Erdős 站点上学会的「gaslight 模型、交叉检查、死磕到底」，与实验室内部的 harness 其实是同一类东西，只是后者被产品化、规模化了。ten-proofs 的 `framework: Codex` 标注，应放在这条谱系里理解：研究方法首先是长期任务编排，其次才是单次推理的聪明程度。

2.2 诞生节点：2026 年 8 月 1 日的一次打包发布

仓库元数据很干净：

- 仓库：`openai/ten-proofs`
- 创建时间：2026-08-01
- 描述：Lean certificates accompanying proofs in mathematics and theoretical computer science
- 主语言：Lean
- 许可证：Apache-2.0
- 配套文章：Ten advances in mathematics and theoretical computer science
- 论文 PDF：`https://cdn.openai.com/pdf/ten-proofs-oai.pdf`

- 推理叙事 PDF：`https://cdn.openai.com/pdf/reasoning-walkthroughs.pdf`

仓库几乎是一次性投下：截至调研时，主分支可见提交极少（公开记录里有 Boris Alexeev 在 8 月 2 日的提交），Issues 被关闭，没有传统软件项目那种迭代节奏。它更像「研究附件」而不是「持续演进的库」。

十个结果横跨八个左右的子领域：

1. 高维球堆积（Cohn–Elkies 线性规划渐近阈值）
2. 二元码与球面码上界
3. 非 sofic 群的存在性构造
4. Connes 刚性猜想的反例
5. 算术电路复杂度：permanent 的公式/电路下界
6. 量子平行重复定理
7. 最近向量问题（GapCVP）的多项式因子硬度
8. Ehrhart 体积猜想的尖锐界
9. 多色三角 Ramsey 数的超指数下界（Erdős 183）
10. 极值图论中的 compactness / degeneracy 猜想反例（Erdős 146、180）

论文正文本身就是一部按章节展开的数学文集，不是「方法论文」。方法信息主要藏在博客声明、`formalization.yaml`、Comparator 配置，以及 reasoning walkthroughs 里。YFarmX 等二手梳理还指出若干值得写进时间线的细节：全文约 249 页；walkthrough 约 62 页；球堆积章节自称是 1978 年以来对一般球堆积指数的首次改进；非 sofic 群问题可追溯到 Gromov / Weiss 前后约四分之一世纪的开放状态；Connes 章节文末还提到，Shuoxing Zhou 同期借助 GPT-5.6 Sol 也独立得到反例——同季并发、双方都不知道对方，这种「同时发现」在 AI 加速下变得异常密集。

发布当日，Erdős Problems 数据库未必立刻改状态。维护者本就声明状态反映个人当前信念，手工更新跟不上公司新闻节奏。这不是对结果的否定，恰恰说明 ten-proofs 试图缩短的，正是「宣称」与「共同体登记」之间的空窗：Lean 证书让空窗里的正确性争议可以并行推进，而不必所有人都先排队等一位专家读完 249 页。

从 5 月到 8 月：方法如何一步步变硬

把 OpenAI 相关数学发布按「验证硬度」排序，会看到清晰升级：

1. **单位距离（2026-05）**：自然语言证明 + 顶尖数学家评注背书。信任来源主要是人。
2. **Cycle Double Cover（约 2026-07）**：模型（GPT-5.6 Sol Ultra）在多 agent 编排下给出证明；随后出现外部研究者主导的 Lean 形式化（如 CDC_lean）。信任开始向机器迁移，但形式化最初并非官方一等公民。

3. **凸优化间隙等个例**：领域专家长 prompt + 模型 + Lean 验证，展示「人定方向、机填证明」的协作模式。
4. **ten-proofs（2026-08-01）**：十个跨领域结果，官方自带零 sorry 证书、公理清单、Comparator 挑战与机构归因声明。验证硬度被做成默认配置，而不是事后补丁。

这条升级曲线很重要。它说明 OpenAI 不是突然「学会了形式化」，而是在连续公共压力下，把每一次发布都当成规范试验：哪些信任机制够用，哪些会被 Bloom 式归因批评打穿，哪些必须预装进仓库。

2.3 研究方法论：一条五段流水线

若把 ten-proofs 当作「研究方法」而不是「结果陈列柜」，其核心可以拆成五段。

阶段 A：选题——用「十年停滞」做难度过滤器

多家报道（含 BleepingComputer、Developers Digest）转述 OpenAI 的筛选口径：这些问题的 **核心结果至少十年没有实质进展**，多数更久。这不是随机挑十道「看起来难」的题，而是用时间停滞当 proxy，降低「其实文献里早有人做过、只是没被索引到」的假阳性——Bloom 站点上 hobbyist 反复踩过的坑。

选题还有第二个维度：**领域分散**。球堆积、算子代数、量子信息、格密码、极值组合同时出现，说明评估目标不是某一条数学线上的专项微调，而是通用研究型推理在陌生子领域迁移的能力。这与 MiniF2F / PutnamBench 那种「同分布竞赛题」评估形成对照。

第三个维度是**共同体兴趣**。官方表述强调：这些问题对各自社区有实质兴趣，其中若干对更广泛数学界也重要。换句话说，选题同时服务科学意义与公关可辨识度——Erdős 问题、Connes 猜想、球堆积，都是「外行也听得懂名字」的对象。

还可以读出第四个、更隐蔽的选题逻辑：**陈述可形式化**。十个结果大多能被压成清晰的全称/存在陈述——「对一切维度成立某极限」「存在满足某性质的群」「某复杂度下界」「某猜想的定量反例」。这类陈述天然适合 Lean。反过来，高度定义开放性、依赖品味判断的「漂亮理论重建」，很难成为第一批证书型发布的主角。研究方法因此带有选择偏差：它偏好「可机器关门」的问题，不一定代表数学中最重要的问题，但代表当下 AI 发布最能防守的问题。

十年停滞过滤器也有代价。它可能系统性地偏好「长期卡住、但或许只需已知工具重新组合」的题目——Cycle Double Cover 被 Bloom 评价为短而初等、本可以在 1980 年代被发现，正是这类风险的提醒。ten-proofs 里的非 sofic 与 Connes 反例看起来更重，球堆积渐近则直接改写 1978 年指数；不同题目的「真正难度」并不均匀。方法上应把「十年无进展」理解成**必要的粗筛**，而不是充分的难度证明。

阶段 B：发现——内部 Astra 在评测期「找到论证」

官方链路说得很短：结果来自 Astra 的内部版本，在开发期评估中取得；找到这些解所需 token，按 Sol API 价格大约 2000 美元。`formalization.yaml` 进一步写明：

- automation method: `agent`
- models: `Astra (OpenAI)`
- framework: `Codex`
- wall_time: `1 week`

这几行信息密度很高。它暗示工作方式不是「单次 completion 吐出终稿」，而是 Codex 框架下的 agent 循环；时间尺度是周级，不是秒级 demo。成本被故意写成「任何有经费的实验室都能负担」的量级——这是在回应 Leiden 宣言里「算力不平等」的指控，至少在推理成本这一层。

公开材料**没有**给出完整 prompt、搜索树结构、失败率、并行采样宽度、是否有人类在发现阶段插手选题或提示关键文献。因此我们能确认的是「成本上界与框架标签」，不能确认「可完全复现的实验协议」。这一点后文会当作方法学短板讨论。

YFarmX 对 2000 美元数字的拆读值得保留：它是「找到解」的 token 成本，按当前 Sol 商业价折算，不是整个研究项目的全成本；它不包含一周 wall time 的机会成本、人类整稿时间，也不包含形式化那一轮。即便打完这些折扣，把「二十多年开放的问题」与「两千美元量级推理账单」并置，仍会改变人对研究边际成本的直觉。方法学上，OpenAI 在做一件很少见的事：给发现过程标价。标价既是透明度，也是叙事武器。

与 7 月 CDC 事件对照，还能看出发现策略的连续性。CDC 报道强调：假设证明存在、禁止轻易宣告未解决、要求长时间坚持、多 agent 并行。ten-proofs 没有公开同等细节，但 Codex agent + 一周 wall time 的组合，强烈暗示同类 harness：把「放弃」变得昂贵，把「交叉验证」变得默认。若这一判断成立，则 Astra 的「聪明」与编排的「固执」是共同变量；只谈模型、不谈 harness，会误判方法。

阶段 C：整稿——人 + 同一模型把论证写成论文

官方说法是：arguments 由系统生成；随后 humans with the same model 把它们整理成 manuscript。论文署名为 OpenAI，没有列出个人作者。这与 5 月单位距离论文的署名策略一致，也与 Leiden「AI 不该被写成人类作者」的压力形成张力：OpenAI 选择把机构写成作者，同时明确声明「数学论证由系统产生，人负责正确性」。

整稿阶段的意义常被低估。研究数学的传播介质仍是可读论文，不是 Lean 文件。Walkthrough PDF 的摘要写明：这些笔记是模型阅读原始思维链与最终文稿后，重建「想法如何汇合」的叙事——包括先走通的路径、撞墙的弯路、视角切换、决定性洞见。也就是说，他们不只发布「正确的证明」，还试图发布「可被人类消化的发现过程替代物」。

对共同体来说，这比裸 dump 200 页 AI 证明更可操作；对方法学来说，这也承认一个现实：机器校验解决的是正确性，解决不了可理解性。

整稿阶段还有一层政治含义。Leiden 宣言主张 credit 与 responsibility 都属于人类，不应授予自动系统。OpenAI 公开链接该宣言，表示尊重，却在署名上拆开两半：接受责任，拒绝把人类写成数学论证的作者。具体操作是机构署名 “OpenAI”，致谢里出现真实数学家——例如报道提到 Connes 章感谢 Popa、Charles、Houdayer，非 sofic 章感谢 Bradford、Chapman、Dogon、Fournier-Facio——他们扮演的是传统「读稿改进者」，却在一份没有人类作者的文本里承担新功能：证明仍有人类目光扫过历史语境与表述。

这套安排是否会被期刊接受，暂缺定论。但它已经把抽象争论变成具体判例：一份关于 Cohn–Elkies 界、没有个人作者、却有可编译证书的论文，学科要怎么归档？

阶段 D：形式化——把论证再写成 Lean 证书

每个结果对应独立 Lean 模块，例如 `SpherePacking.lean`、`NonSoficGroup.lean`、`GapCVP.lean`。工程栈固定为：

- Lean 4.32.0
- mathlib（`leanprover-community`，rev `v4.32.0`）
- Lake 构建
- `lake exe cache get && lake build All`

`formalization.yaml`（v0.3）是这份仓库最像「研究元数据标准」的文件。它声明：

- 全局 `sorry_count: 0`，定义中也无 sorry
- 仅使用经典数学常见的三条公理：`propext`、`Classical.choice`、`Quot.sound`
- 12 个主定理声明（覆盖 10 个结果；有的结果对应多个声明）
- 每个主结果绑定 Comparator 配置
- review status: `agent-reviewed`
- 致谢 Sphere-Packing-Lean 先验工作

文件体积也能侧面说明形式化强度：若干模块达到百万到五百万字节量级（如 MetricCodes、GapCVP），说明不是「声明一句定理 + 调用库」的薄包装，而是大规模形式化工程。

公开信息把形式化也归因给模型（Astra 在人类协助准备后完成 Lean 化）。仓库依赖 Comparator，并为每个挑战提供 JSON：指定 challenge/solution module、定理名、允许公理、`enable_nanoda: true`。Comparator 来自 Lean FRO，可在沙箱中检查：证明的是不是同一陈述、公理是否越界、内核是否接受；还能走独立的 nanoda 内核，降低「只信任 Lean 自家内核」的单点风险。

这一步把验证从「请专家读三个月」改成「任何人可以 `lake build` / `lake exe comparator ...`」。它没有取消同行评议对意义、新颖性、文献定位的判断，但把正确性争议的门槛大幅抬高。

形式化也引入新的方法风险，OpenAI 自己的评论者与二手分析都点到了：**Lean 证明「同一个声明」不等于证明「领域关心的那个猜想」**。把自然语言中的 Connes 刚性、sofic 近似、Ehrhart 条件翻译成类型论语句，本身就是数学判断。证书保证演绎封闭，不保证形式化忠实。`review: agent-reviewed` 进一步提醒：连形式化审阅目前也主要是 agent，不是领域编辑部。因此，ten-proofs 最强之处与最需警惕之处是同一枚硬币——它把正确性检查工业化了，却把「声明是否说对了问题」留在更细的专家劳动里。

Sphere-Packing-Lean 先验工作出现在 acknowledgements / prior_work 字段里，说明形式化并非从文化真空开始。球堆积方向已有社区积累，Astra 的证书站在既有 Lean 数学之上。方法上这很正常，但对外传播若只强调「模型一周做完」，会抹掉基础设施劳动。好的研究方法叙事应当同时记账：模型推理、人类整稿、社区库、检查器工具，四笔账都在。

阶段 E：发布与归因——用开放工件回应制度压力

发布包几乎按「审计清单」设计：

工件	作用
博客帖	宣布结果、说明流水线、回应 Leiden
长篇论文 PDF	人类可读数学论证
reasoning walkthroughs	发现过程叙事，降低黑箱感
Lean 仓库	机器可检查证书
formalization.yaml	公理、sorry、定理声明、自动化元数据
ComparatorChallenges	独立二次校验入口

归因立场可以概括成四句：

1. 不把完全由 AI 生成的证明写成人类作者的智力成果。
2. 机构（OpenAI）对正确性负责。
3. 人类参与了文稿准备与形式化协助。
4. 希望数学共同体接手：定位意义、发展后续、把想法真正「养活」。

这不是单纯道德宣言，而是方法学的一部分：当证明生产速度超过人类阅读速度时，**署名诚实 + 机器校验**变成维持学科信任的最低配置。

2.4 前史如何「锁死」了这条方法路径

把时间线拉长，ten-proofs 的方法选择几乎被几个前序决策锁定。

第一，Lean 成为默认证书语言。 2024–2025 的 IMO 形式化竞赛、mathlib 生态扩张、Comparator / nanoda 一类工具出现，让「公开 Lean 文件」逐渐变成 AI 数学结果的硬通货。OpenAI 若只发自然语言证明，会被 Aristotle / Seed-Prover 阵营用「人类裁判也可能看走眼」反将一军；若发 Lean，就能把战场挪到可编译性。

第二，单位距离事件重塑了发布模板。 5 月那次已经试验了「机构署名 + 专家评注 + 公开 PDF」。ten-proofs 把专家评注替换成更强的东西：机器证书 + 独立核。从「请大牛背书」升级到「请内核背书」，这是信任机制的迁移。

第三，Codex/agent 框架把证明搜索产品化。 yaml 里写 framework: Codex，说明他们把数学发现放进与软件工程 agent 同源的工具循环：读写、尝试、反馈、再尝试。数学不再被当作纯聊天补全，而被当作长期任务。

第四，Erdős 问题生态提供了公共靶面，也暴露了旧评估的脆弱。 hobbyist 用公开模型刷题、文献检索失败、无人阅读的超长 AI 论文泛滥——这些都在逼实验室回答：你们的结果凭什么可信？ten-proofs 的答案是：十年停滞过滤器 + Lean + Comparator + 明确归因。

2.5 阶段划分：萌芽、转向、制度化

若给 OpenAI 的 AI-math 方法史做粗分：

萌芽期（至 2025）：竞赛与内部评测为主，能力叙事跟着 IMO / 基准走；形式化多在外部社区与竞品那里更显眼。

冲击期（2026 年 5–6 月）：单位距离反例证明「研究级开放问题」可被内部模型击穿；Leiden 宣言同步抬高规范要求；数学家开始用「Annals 级」语言评价 AI 证明。

制度化发布期（2026 年 7–8 月）：公开材料显示 Cycle Double Cover、凸优化间隙等 Lean 验证结果陆续出现；8 月 1 日 ten-proofs 把「多领域开放问题 + 全量形式化 + 元数据规范」一次性摊开。Astra 名称随之从传言变成有公开数学战绩的内部模型标签。

到本稿写作时（发布后第三天），仓库已有数百 star，但学术共同体的深度消化显然还没完成——十个领域各自需要不同专家团。方法已经发布；意义评估才刚开始。

也可以把这一阶段理解成「从模型能力展示，转向制度能力展示」。5 月证明模型能做出 Annals 级论证；7 月证明多 agent 能在小时级啃下图论名题；8 月则证明实验室愿意把正确性工具链、归因立场和成本数字一并摊开。三次发布叠在一起，才构成完整的方法演进，而不是三次互不相关的公关。读 ten-proofs 若不把前两次放进同一条纵轴，很容易把它误看成突然空降的十个定理，而看不到背后那条越来越硬的信任协议升级路径。

2.6 仓库结构本身也是方法声明

读目录比读新闻更能看懂他们想让外部做什么：

- 根目录十个结果模块 + `All.lean`：方便一键编译全套
- `ComparatorChallenges/*.{lean,json}`：把「如何独立检查」产品化
- `formalization.yaml`：把 sorry/公理/自动化信息写成机器可读声明
- 几乎没有 Python 训练代码、没有搜索算法实现、没有数据集

所以研究方法的「可复现部分」主要是**验证复现**，不是**发现复现**。外部实验室可以复核证书是否成立；很难按同样协议重跑 Astra 的发现过程。对科学方法而言，这是半开放：结果可审计，过程仍专有。

这种半开放不是疏忽，而是商业实验室做研究发布时的稳态结构。ten-proofs 把它表达得很露骨——甚至露骨得有方法论自觉。

2.7 十个结果在方法上的共性，而非数学内容复述

不逐题展开技术细节（那是 249 页论文的工作），只看它们对「研究方法」意味着什么。

共性一：**多数是构造或界的改进/反例**，不是纯存在性空话。反例与显式构造特别适合形式化，因为目标陈述清晰：「存在满足 P 的对象」「对一切参数成立某不等式」。

共性二：**跨领域借用工具**。单位距离已展示模型会把数论塔搬进离散几何；walkthrough 目录显示球堆积走到 Fourier / Mellin / 调和测度，非 sofic 群走到 property (T) 与 Leavitt 代数，GapCVP 走到特征 2 的矩直方图与 Hankel 重建。方法上的主张是：通用模型能在「人类专家未必立刻跨界」的地方做远距离联想。

共性三：**失败路径被写进公开叙事**。walkthrough 反复出现 “long detour”“why the first approach was wrong”。这不是装饰，而是在对抗「AI 只会最终答案、没有研究过程」的批评。当然，这些叙事由模型事后重建，是否忠实于真实搜索轨迹，公开材料无法独立核验——需要标注为「有限透明」。

共性四：**形式化覆盖主定理，不等于覆盖论文全部旁白**。Comparator 绑定的是声明列表中的核心定理。方法上应区分：机器证明了什么、论文还声称了什么、哪些启发性讨论仍停留在自然语言层。

若按「证明对象类型」再切一刀，十个结果大致落入三类方法原型：

1. **尖锐渐近/界的确定**（球堆积、码、Ehrhart、部分复杂度下界）：关键是找到正确的解析对象或组合证书，并证明上下界咬合。
2. **反例/显式构造**（非 sofic、Connes、极值图论猜想）：关键是造出违背直觉的对象，并验证它满足一长串性质。
3. **归约与定理强化**（GapCVP、量子平行重复、Ramsey 下界）：关键是把难题连回已知硬核，或把已知原理推到过去够不着的一般情形。

三类对 agent 的压力不同。构造类吃「远距离类比 + 耐心验证」；尖锐界类吃「选择正确解析框架」；归约类吃「复杂度证明的细账」。ten-proofs 把三类捆进同一发布，等于主张 Astra 不是某一证明模式的偏科生。对方法论读者，这比「十个都很难」更有信息量：它在测的是模式覆盖，而不只是单点运气。

并发发现的插曲也该写进方法史。Connes 反例在同一季节被 Zhou（借助 GPT-5.6 Sol）独立得到，说明当模型能力越过阈值，开放问题的「剩余寿命」会集体缩短，优先权纠纷与同时发现会变日常。研究方法若仍按前 AI 时代的单打独斗节奏设计投稿与署名，会持续产生摩擦。ten-proofs 选择机构署名 + 致谢读稿者，某种程度上是在为这种高并发世界预演新惯例。

2.8 尚未闭合的方法学问题

诚实列出公开信息的空洞，本身也是研究这份库的一部分：

1. **发现阶段人类介入程度暂缺精确披露。** 「arguments generated by the system」与「humans helped prepare manuscripts and formalize」之间的边界，对外仍偏粗。
2. **题库如何生成、失败题占比多少暂缺。** 我们看到的是成功的十个，不是评估集全貌。
3. **Astra 架构、是否专用数学 RL、与 GPT 系列关系暂缺。** 只有 “next major model / internal version” 级描述。
4. **agent-reviewed 的具体协议暂缺。** yaml 写了 review status，但没有公开审稿清单或交叉验证记录。
5. **社区接受度仍在早期。** 正确性可机器检查；重要性、优先权、文献归因是否充分，仍取决于各领域专家。

这些空洞不否定结果，但限制我们把 ten-proofs 误读成「完全开放的可复现科学实验」。它更准确的身份是：**高标准公开的研究主张 + 可独立核查的正确性证书。**

三、横向分析：竞争图谱

3.1 竞品场景判断：场景 C（充分竞争，但赛道正在裂开）

AI 数学不是单赛道，至少裂成三条：

1. **竞赛/基准赛道**：IMO、MiniF2F、PutnamBench、ProofNet
2. **开放问题猎杀赛道**：Erdős 清单、长期猜想、公司内部评测集
3. **形式化基础设施赛道**：mathlib、autoformalization、Comparator、专用 prover 模型

ten-proofs 主要落在第 2 条，并用第 3 条的最强工具给自己背书；它刻意不和第 1 条比分数。横向对比若只比 pass@k，会完全看错对象。

代表性对比对象取四个：DeepMind AlphaProof 系、Harmonic Aristotle、开源 prover（以 DeepSeek-Prover 为代表）、以及 Erdős 社区的「公开模型 + 人工织网」实践。Seed-Prover 等作为同簇提及。

3.2 DeepMind AlphaProof / AlphaGeometry：把形式化搜索做成竞赛武器

AlphaProof 的经典方法画像是：强化学习 + Lean 证明搜索，测试时针对目标题做专用强化；几何则往往走专用系统。2024 IMO 银牌级正式解，是「LLM + ITP + 搜索」进入公共视野的标志事件。

与 ten-proofs 比，差异不在「用不用 Lean」，而在**问题本体论**：

- AlphaProof 优化的是有标准答案、时间盒、可重复评分的竞赛题。
- ten-proofs 优化的是无标准答案、跨十年停滞、需要共同体事后定位意义的研究问题。

方法论后果很具体。竞赛系统可以围绕形式化题库做大规模 RL，用 pass rate 当梯度；开放问题系统必须先解决「什么叫进展」「如何避免重新发现旧结果」「如何让证明进入人类文献」。AlphaProof 更像运动员训练体系；ten-proofs 更像实验室成果发布规范。一个追求可重复的分数，一个追求可辩护的主张。

DeepMind 在 Erdős 清单上也并非缺席：Quanta 记载，2026 年初有 24 人团队用 Gemini 系统评估约 700 条标记为 open 的猜想，解决四题并找回九个被遗忘的旧解；5 月另有团队报告「最强 agent 以每题数百美元成本自主解决 353 题中的 9 题」，且筛选偏向已形式化的问题。这说明横向竞争已从「谁 IMO 更高」扩展到「谁能便宜地清理开放问题」。ten-proofs 的差异化不在「也做开放问题」，而在**样本更苛刻、跨域更深、发布规格更重**：不是九个清单题，而是十个十年停滞、覆盖算子代数与量子信息的旗舰包，并且官方自带 Comparator。

还应注意训练信号差异。AlphaProof 类系统能从证明搜索的成败获得密集反馈；研究级开放问题的反馈极稀疏——大多数尝试以失败或「其实文献里有」告终。OpenAI 选择在开发期评估中「碰巧/系统地」挖到十个赢家再打包，这一披露方式本身就不对称：横轴竞品若只晒成功子集，分数会失真；纵轴读者若把十个成功当成命中率，会高估方法的平均效力。

3.3 Harmonic Aristotle：正式证明优先的产品化路线

Aristotle（arXiv:2510.01346）把系统拆成 Lean 搜索、非正式引理生成/形式化、专用几何求解器，搜索侧使用 Monte Carlo Graph Search 一类 hypertree/hypergraph 结构。它强调：只返回通过 Lean 的结果；2025 IMO 五题正式解，走金牌等价叙事，并推进 API 化。

Aristotle 与 ten-proofs 共享「Lean 是真理源」的信仰，但产品目标不同：

维度	Aristotle	ten-proofs
主场景	竞赛题与可请求的证明服务	一次性研究级结果发布
系统公开度	有论文描述架构组件	几乎只公开产物，不公开系统
验证	Lean 编译	Lean + Comparator/nanoda + yaml 元数据
成功度量	IMO/基准与可用性	十年开放问题突破 + 共同体接手

若问「谁更像可部署的证明系统」，是 Aristotle。若问「谁更像把 AI 数学发现抬到科学出版新规范」，是 ten-proofs。一个卖能力接口，一个卖研究主张的可信封装。

Aristotle 论文还点破一个横向关键分歧：OpenAI / DeepMind 的部分 IMO 金牌叙事建立在自然语言解与人类裁判上；Aristotle / Seed-Prover 坚持正式解。ten-proofs 站到了后者的验证哲学一边，却又保持前者的「通用大模型发现」气质——它不像专用 ATP 产品，更像通用模型在研究评测中的战报，只是战报附带了 ATP 级证书。这种混血身份，使它很难被单一赛道的排行榜收编。

ByteDance 的 Seed-Prover 与 Aristotle 同属「正式 IMO」簇，横向意义在于：形式化金牌不再是一家独有叙事。当竞赛侧被多家填满，差异化必然上移到开放问题与发布规范——这正是 ten-proofs 出现的产业逻辑。

3.4 DeepSeek-Prover 等开源路线：把方法敞开放进训练配方

DeepSeek-Prover-V2 的公开方法很「学术论文友好」：用通用模型做子目标分解与形式化，小模型搜索子目标，合成 cold-start，再以 Lean 二元正确性做 RL。后来还有 Pythagoras-Prover 一类工作继续卷 MiniF2F / PutnamBench 的计算效率。

这条线的核心贡献是**可训练、可复现、可本地跑的 prover 方法论**。它回答「怎样学证明」；ten-proofs 回答「怎样发布证明」。两者并不直接互替。实际上，ten-proofs 这种大规模研究级形式化产物，未来反而可能成为开源 prover 的高价值训练/评测素材——前提是许可与归属被正确处理。

开源路线目前仍明显更强于竞赛分布内的正式证明，弱于跨领域开放问题的自主发现。ten-proofs 展示的是闭源前沿模型在发现端的跳跃；开源阵营展示的是方法透明与可分发。

从研究方法转让的角度看，开源 prover 回答的是 Kuhn 所谓「范式的可学习性」：外人能否按配方重做。ten-proofs 回答的是「主张的可检验性」：外人能否按证书复核。科学史上这两种开放并不总是一起出现——有时公开配方但结果难复核，有时公开结果但配方保密。2026 年的 AI 数学刚好把这两种开放拆给了不同阵营。一个健康的生态需要两边都在；只有战报没有配方，会走向神谕；只有配方没有旗舰结果，又难以证明方法触及研究前沿。

Mistral 的 Leanstral 等开放权重模型被 Developers Digest 提及为 miniF2F 饱和的对照。横向含义是：形式语言输出正在成为多厂商默认，不再是 DeepMind 专属美学。ten-proofs 选择 Lean，因此也是在这一收敛上下注。

3.5 Erdős 社区实践：低成本、高噪声、真问题

Quanta 描述的社区方法几乎是人肉 agent 循环：诱导模型相信问题不难、多实例交叉检查、再用 Aristotle 等工具做形式化、请真正数学家复核。单价可以很低，产量可以很高，但也制造大量无人阅读的超长 PDF，以及「标记为 open 其实早被解决」的文献事故。

相对这套草根方法论，ten-proofs 像是实验室版纠偏：

- 用十年停滞降低「假开放」
- 用机构署名与责任声明降低「匿名垃圾证明」
- 用 Lean/Comparator 降低「看起来像证明」
- 用 walkthrough 试图降低「不可读」

社区的优势是开放性与题目覆盖面；实验室的优势是单题深度与发布规范。2026 年的真实图景不是谁取代谁，而是两者互相提供原料：社区提供题面与快速试错，实验室提供高规格结果与模型能力上限。

社区还暴露了评估污染问题。一旦某清单成为 PR 战场，人类研究者的参与动机、题目的「剩余趣味」、甚至 open/closed 标签的维护质量都会被扭曲。Alon 停止做 Erdős 题、Tao 减少在该社区停留，是横截面上的真实用户行为，不是外生噪声。ten-proofs 把战场迁到十年停滞的高声望问题上，短期能避开「刷清单」讥讽，长期仍可能制造新的挤出：当 Connes、球堆积也开始频繁出现在公司博客里，谁还愿意把职业生涯押在下一道可能被周末 agent 清掉的题上？研究方法评估如果只计算解题数量，会漏掉这种激励系统的崩坏。

另一个社区教训是归因。CDC 证明被称赞为漂亮，也被批评对 Bermond–Jackson–Jaeger 等先验策略引用不足。ten-proofs 在球堆积形式化上点名 prior_work，在若干章节致谢专家读稿，比早期战报更完整，但仍无法自动解决「模型训练语料里吸收了谁的思想」这一深层归因难题。Leiden 要求的 proactive attribution，对闭源模型而言几乎是结构性难题：模型自己也说不清师承。walkthrough 展示思维故事，却替代不了参考文献学。

3.6 方法对比总表（研究视角）

维度	ten-proofs / Astra	AlphaProof 系	Aristotle	DeepSeek-Prover 系	Erdős hobbyist 流程
目标	研究级开放问题突破	竞赛金牌/银牌	竞赛 + 正式证明产品	基准 SOTA / 开源 prover	清理清单上的开放题
问题选择	十年停滞 + 多领域	正式竞赛集	IMO 等	MiniF2F 等	Bloom 清单
发现机制	内部 agent（Codex/Astra）	RL + 搜索	MCGS + 引理管道	子目标分解 + RL	多轮提示/交叉审查
验证闭环	Lean + Comparator/ nanoda	Lean	Lean	Lean	偶发 Lean/人工
人工角色	整稿、负责正确性	系统研发/评测	系统研发/产品	训练与开源	选题、催促、找专家
可复现重点	证书可复核	部分论文级复现	部分架构公开	模型与配方公开	流程可抄，结果不稳
透明度短板	发现协议专有	系统细节有限	权重/服务受限	距研究级发现仍远	文献与正确性噪声
生态位	高规格研究发布模板	竞赛形式化标杆	正式证明商业化	开放训练基础设施	分布式开放问题淘金

3.7 用户与共同体口碑：赞的是能力，争的是意义与规范

正面声音很强：单位距离阶段已有 Gowers「Annals 级」评价；Alon 称 AI 正剧烈改变研究方式；Quanta 把 8 月十结果写成能力相变的证据链。Developers Digest 一类技术评论则抓住 Lean 证书与 2000 美元成本：验证方式变了，研究成本账也变了。

保留意见同样尖锐，且多半不是否认编译通过：

- Leiden 阵营担心闭源、归因、炒作与议程失控。
- Bloom 警告不会验证的人批量生产长文。

- 部分数学家从 Erdős 题上撤退，因为「AI 开始做了就没意思了」——这是动机危机，不是正确性危机。
- 对 ten-proofs 特有的疑虑会是：十个结果是否都被各自领域消化？walkthrough 是否美化了搜索过程？「agent-reviewed」能否替代传统审稿？

横向看，ten-proofs 目前最像把争论从「AI 会不会做数学」推进到「AI 数学结果应当以什么制度被接收」。

口碑场里还有一类「冷静技术读者」：他们不一定在乎 Connes 猜想的史学地位，却立刻去看 `formalization.yaml` 和 Comparator JSON。对这群人，研究方法的可读界面已经从博客散文变成了清单式元数据。谁能把 sorry、公理、定理名、检查命令写成可执行规范，谁就更像在做工程化科学。ten-proofs 在这个细分读者群里的得分，甚至可能高于它在传统数学家群里的即时得分——因为后者仍需数周消化每个领域章节。

3.8 ten-proofs 的生态位：填补的是「研究发布规范」空白

竞赛赛道已经拥挤；开源 prover 赛道也拥挤；真正稀缺的是：

> 当模型真的对长期开放问题给出新论证时，怎样发布，才既不被指控黑箱欺诈，又不强迫整个学科退回「只信口头权威」。

ten-proofs 给出的临时标准大致是：

1. 选题说明难度代理（十年停滞）
2. 成本与框架量级披露
3. 人类/AI 贡献边界声明
4. 自然语言论文 + 过程叙事
5. 零 sorry Lean 证书
6. 公理清单
7. 独立证明检查器配置

它未必是最终标准，但已经是 2026 年夏最完整的公开模板之一。竞品可以在分数上压过它，却很难否认：这套发布规格抬高了行业地板。

四、横纵交汇洞察

4.1 历史如何塑造了今天的位置

ten-proofs 今天的位置，几乎是被前两件事焊死的。

没有 5 月的单位距离冲击，OpenAI 不必这么快把「研究级发现」当成主叙事；没有 6 月 Leiden 的规范压力，它也不必把归因、责任、形式化做成如此显眼的发布配件。仓库看起来像数学结果集，骨架却是一套**信任工程**。

同时，若没有 Lean 生态在竞赛年代被 AlphaProof / Aristotle / 开源 prover 共同养肥，OpenAI 也拿不出 Comparator + nanoda 这种「二次内核」话术。纵轴上的能力跃迁，借到了横轴上基础设施成熟的东风。

4.2 把竞品也放到时间线上：三条进化路径

- **DeepMind 路径**：竞赛形式化 → 证明搜索与几何专用系统 → 再向开放问题清单延伸。强项是系统方法清晰、竞赛战绩早。
- **Harmonic 路径**：正式证明优先 → IMO 金牌等价 → API/产品。强项是「不通过 Lean 就不输出」。
- **OpenAI 路径**：通用推理模型 → 研究级单点突破（单位距离）→ 多领域批量突破 + 发布制度化（ten-proofs）。强项是发现端的广度与公关/规范打包能力；短板是系统细节最不透明。

开源 prover 路径平行前进：把「如何训练」讲清楚，但还没在「十年开放问题批量突破」上形成对等事件。

4.3 优势的历史根源

广度优势来自通用模型路线：不先做球堆积专用系统，才可能一周内跨八个区块出活。

可信度优势来自竞赛年代留下的 Lean 工具链，加上单位距离后被迫学会的署名与责任话术。

成本叙事优势来自把 token 账单公开写成约 2000 美元——把「神秘算力神迹」改写成「可定价的研究流程」。这在横轴上直接打击「只有巨头玩得起」的简单批评，尽管发现模型本身仍不开放。

可审计优势来自把 formalization.yaml / Comparator 当作一等公民，而不是 README 里的一句 “also formalized”。

4.4 劣势的历史根源

过程不透明几乎是闭源通用模型策略的宿命：能公开的是产物，不能公开的是数据、强化学习信号与完整评测集。早年为产品保密做的选择，今天变成科学可复现性的债务。

「成功样本发布」偏差也有历史原因。公司评估天生展示赢家；科学评估需要分母。十年停滞过滤器提高了单题含金量，却仍无法告诉我们 Astra 在更大题库上的命中率。

可读性与意义生产仍依赖人类。机器可以保证「这步不错」，不能自动保证「这结果在该领域意味着什么、该引用谁、该怎样简化」。walkthrough 是在补这块，但它自己也是模型生成的二手叙事。单位距离之后人类数学家迅速改进结果的故事提醒我们：AI 突破往往是新研究的起点，不是终点。

动机挤出效应同样值得写进方法评估。当 Alon 说「AI 开始做 Erdős 题就没必要再做」，说明评估集一旦变成公司 PR 战场，会反噬人类研究者的内在动机。ten-proofs 选更硬的十年问题，部分缓解「刷清单」印象，却也可能把挤出效应推到更高声望的问题上。

归因结构困境则来自深度学习本身。模型无法提供可审计的思想谱系，实验室只能用致谢、prior_work 字段和「机构担责」做外部修补。CDC 阶段已被指出的引用不足问题，不会因为有了 Lean 就自动消失——证书不问你是否公平对待了 1983 年的论文。

把这些劣势放回纵轴看，它们几乎都不是 8 月 1 日才产生的新锅，而是长期路线选择在「突然需要像科学」时暴露的旧账。ten-proofs 的高明之处在于：它没有假装旧账不存在，而是用证书与声明把旧账能补的部分补上，不能补的部分至少标出来。

4.5 未来三个剧本

最可能的剧本：双轨常态化。
一边是公开模型与社区继续低成本清理中等开放问题；一边是前沿实验室用 Astra 级模型做高规格、全形式化的「旗舰结果包」。期刊与学会逐步形成披露模板：模型、成本量级、人类角色、Lean 证书、公理列表。Lean 继续充当跨境共同语。ten-proofs 成为被引用的发布先例，而不是孤例。

最危险的剧本：证书崇拜与意义空洞。
共同体过度把 `lake build` 成功等价于「好数学」，放松对新颖性、归因、简化与可教学性的要求。大批形式化正确但无人理解的论文堆积；年轻研究者要么卷不过闭源 agent，要么沦为证书搬运工。Leiden 担心的自主性流失，以「一切皆可编译」的乐观面具出现。

最乐观的剧本：人机分工被重建。
模型负责远距离联想、构造搜索、形式化苦力；人类负责问题选择、意义判断、简化重构、开辟新定义。OpenAI 在文末希望共同体「bring the ideas to life」若真发生，ten-proofs 里的每个结果都会派生出更短的人类证明、更广的推广、新的反例与新理论。届时仓库的历史地位，不是「AI 赢了数学」，而是「数学找到了与 AI 共事的交接仪式」。

4.6 回环：这份库到底研究了什么

开头说过，ten-proofs 卖的不是十个答案，而是一条流水线。

把纵轴与横轴交叉后，我的判断是：

它研究的真正对象，是**后竞赛时代 AI 数学的科学方法**：在模型已经能偶然（或系统地）击穿长期开放问题时，怎样让结果进入数学的信任秩序，而不只是进入新闻秩序。

Lean 证书是秩序的硬约束；十年选题是难度的代理指标；2000 美元是成本的去神秘化；OpenAI 署名是归因的诚实实验；walkthrough 是可理解性的临时补丁。每一项都有缺陷，但组合在一起，已经比「一篇博客 + 一段看起来很像证明的 LaTeX」更接近一门学科能接受的最低礼貌。

若只把这个仓库当成「OpenAI 又炫耀了」，会看轻它。若把它当成「可复现的 Astra 训练代码」，又会看错它。它是一份方法学文物：记录 2026 年夏，一家前沿实验室选择用什么仪式，把机器做出的数学送进人类的知识制度。

五、信息来源

1. OpenAI 官方博文：https://openai.com/index/ten-advances-in-mathematics/（访问：2026-08-04）
2. 论文 PDF：https://cdn.openai.com/pdf/ten-proofs-oai.pdf（访问：2026-08-04）
3. Reasoning walkthroughs：https://cdn.openai.com/pdf/reasoning-walkthroughs.pdf（访问：2026-08-04）
4. GitHub 仓库：https://github.com/openai/ten-proofs（访问：2026-08-04；含 README、lakefile.toml、formalization.yaml、ComparatorChallenges）
5. Leiden Declaration：https://leidendeclaration.ai/（访问：2026-08-04）
6. Quanta Magazine, *Why the Legendary Erdős Problems Are Falling to AI*：https://www.quantamagazine.org/why-the-legendary-erdos-problems-are-falling-to-ai-20260803/（2026-08-03）
7. Developers Digest 技术解读：https://www.developersdigest.tech/blog/openai-ten-advances-mathematics-lean-2026（访问：2026-08-04）
8. BleepingComputer 报道（十年停滞与 Astra 定位）：https://www.bleepingcomputer.com/news/artificial-intelligence/openai-teases-astra-its-next-major-ai-model-after-it-solves-10-long-standing-math-problems/（访问：2026-08-04）
9. Aristotle 论文：https://arxiv.org/abs/2510.01346（Harmonic；IMO-level ATP）
10. DeepSeek-Prover-V2：https://github.com/deepseek-ai/DeepSeek-Prover-V2 ；论文 https://arxiv.org/html/2504.21801v2
11. 单位距离评注稿相关：arXiv:2605.20695 *Remarks on the disproof of the unit distance conjecture*
12. Lean Comparator：https://github.com/leanprover/comparator（由仓库 README/依赖引用）
13. 二手综述补充：https://pasqualepillitteri.it/en/news/9274/astra-ten-open-problems-lean-proofs ；https://yfarmx.com/openai-astra-ten-proofs-lean-certificates/

14. Cycle Double Cover 相关：OpenAI PDF https://cdn.openai.com/pdf/04d1d1e4-bc75-476a-97cf-49055cd98d31/cdc_proof.pdf ；Scientific American / The Decoder 等报道；外部 Lean 形式化说明 https://j-carmesin.github.io/publications/Cycle_double_cover.pdf
15. Leiden / IMA 相关报道：https://ima.org.uk/29314/ai-is-challenging-the-core-values-of-mathematics-researchers-call-for-urgent-action/

说明：OpenAI 博文页面存在反爬/JS 门槛，正文要点结合官方 PDF、仓库元数据与多家转述交叉核对；涉及 Astra 内部架构、完整评测集与发现阶段人工介入细节，公开信息不足处已在正文标为暂缺，未作脑补。Erdős 数据库状态以发布当日二手观察为准，后续可能更新。

六、方法论说明

本报告采用数字生命卡兹克提出的横纵分析法：纵轴还原 ten-proofs 从 AI 数学竞赛叙事、单位距离事件到制度化发布的历时过程；横轴在 2026 年 8 月截面上与 AlphaProof、Aristotle、开源 prover、Erdős 社区实践对比；最后在交汇处给出关于「研究发布规范」的判断与情景推演。